Problemas de Clustering

- 1. Consideremos la tabla de datos worldcup del paquete faraway que nos información sobre los jugadores de Futbol que participaron en el Mundial de Futbol celebrado el año 2010 en Sudáfrica. Esta tabla de datos da información de 595 jugadores y tiene 7 variables:
- Team: el pais del jugador.
- Position: la posición en que juega el jugador. Tiene 4 valores:

Defender: defensa.Forward: delantero.Goalkeeper: portero.Midfielder: medio.

- Time: tiempo jugado en minutos.
- Shots: número de tiros que ha realizado el jugador.
- Passes: número de pases del jugador.
- Tackles: número de entradas del jugador.
- Saves: número de paradas del jugador.
 - a) Seleccionar una muestra de 25 jugadores usando la función sample. Escribir set.seed(2020) antes de elegir la muestra.
 - b) Aplicar el algoritmo k-means a la muestra anterior usando las variables cuantitativas para clasificar a los 25 jugadores en 4 grupos usando el algoritmo de MacQueen. Aplicar la función kmeans unas cuantas veces con el fin de que la suma de los cuadrados de todos los clusters sea mínima.
 - c) Queremos estudiar hasta qué punto la clasificación anterior coincide con la clasificación de los 25 jugadores según la posición que ocupan. Calcular la tabla bidimensional que dos dé el cluster a qué pertenece el jugador por un lado y la posición a la que juega. ¿Qué porcentaje de aciertos ha tenido el algoritmo k-means?
- 1. Consideremos la tabla de datos worldcup del paquete faraway que nos información sobre los jugadores de Futbol que participaron en el Mundial de Futbol celebrado el año 2010 en Sudáfrica. Esta tabla de datos da información de 595 jugadores y tiene 7 variables:
- Team: el pais del jugador.
- Position: la posición en que juega el jugador. Tiene 4 valores:

Defender: defensa.Forward: delantero.Goalkeeper: portero.Midfielder: medio.

- Time: tiempo jugado en minutos.
- Shots: número de tiros que ha realizado el jugador.
- Passes: número de pases del jugador.
- Tackles: número de entradas del jugador.
- Saves: número de paradas del jugador.
 - a) Seleccionar una muestra de 25 jugadores usando la función sample. Escribir set.seed(2020) antes de elegir la muestra.
 - b) Calcular la matriz de distancias de los 25 jugadores anteriores usando la distancia euclídea entre las variables cuantitativas.
 - c) Usando el método jerárquico aglomerativo del **enlace promedio** hallar el dendrograma para clasificar los 25 jugadores anteriores.
 - d) Clasificar los 25 jugadores en 4 clusters a partir del dendrograma anterior.
 - e) Queremos estudiar hasta qué punto la clasificación anterior coincide con la clasificación de los 25 jugadores según la posición que ocupan. Calcular la tabla bidimensional que dos dé el cluster a qué pertenece el jugador por un lado y la posición a la que juega. ¿Qué porcentaje de aciertos ha tenido el algoritmo aplicado?